```
title: "Business Requirements Document: Plataforma DataOps do CNPJ"
subtitle: "Processamento on-premises de todos os arquivos abertos do CNPJ da Receita Federal, com
monitoramento autônomo por agentes"
author: "Bruno Nunes — Engenharia de Dados"
date: "2026-09-11"
document_type: "BRD — Projeto de portfólio"
classification: "Público"
version: "1.0"
```

Business Requirements Document: Plataforma DataOps do CNPJ

Capa

PLATAFORMA DATAOPS DOS DADOS ABERTOS DO CNPJ

Processar 100% dos arquivos mensais do CNPJ publicados pela Receita Federal, em infraestrutura própria (Docker), transformar em dados confiáveis para **crédito e risco**, **KYC/PLD** e **prospecção comercial**, com um time de agentes de IA que vigia a qualidade e diagnostica falhas.

- **Preparado por:** Bruno Nunes (engenharia de dados)
- **Tipo:** projeto pessoal / portfólio técnico
- **Data:** 11 de setembro de 2026
- **Status:** para revisão
- **Recomendação:** executar em fases, começando pela ingestão e pelo medalhão (Fases 0–2)
- **Arquitetura de referência:** owshq-mec/ws-3-crew-ai-multi-agent, adaptada para arquivos, Airflow e DuckDB

Sumário

1. Sumário executivo
2. Situação atual
3. Problema e impacto no negócio
4. Solução proposta e capacidades
5. Análise de custo e esforço
6. Alternativas consideradas
7. Riscos e mitigação
8. Métricas de sucesso e governança
9. Roadmap de implementação
10. Partes interessadas e personas
11. Registro de premissas e restrições
12. Apêndice: arquitetura-alvo
13. Conclusão

1. Sumário executivo

1.1 Situação

A Receita Federal publica todo mês a base aberta do CNPJ: empresas, estabelecimentos, sócios, opção pelo Simples/MEI e seis tabelas de domínio. Hoje a publicação fica no repositório **SERPRO+** (Nextcloud), num compartilhamento público com **40 pastas mensais, de 2023-05 em diante, somando 311,7 GB**. Cada competência tem **37 arquivos zip e cerca de 6 GB compactados**. Descompactados, os CSVs passam de 80 GB.

É o dado público mais usado no Brasil para conhecer uma empresa: se está ativa, desde quando, o que faz, onde está, qual o porte e quem são os sócios. Três mudanças recentes aumentam o risco de quem consome esse dado:

- **Mudança de endereço.** O diretório antigo `dados/cnpj/dados_abertos_cnpj/` hoje responde "Page not found". Os arquivos migraram para um compartilhamento Nextcloud, acessível por WebDAV.
- **CNPJ alfanumérico.** Desde julho de 2026 (IN RFB nº 2.229/2024), novos CNPJs podem ter letras na raiz e na ordem. O dígito verificador continua numérico.
- **Inconsistências da própria fonte.** A Receita publica códigos que não existem nos domínios do mesmo mês, CEPs sem o zero à esquerda e valores-sentinela (detalhes na seção 2.3).

1.2 Problema

Consumir esse dado de forma confiável exige resolver ao mesmo tempo:

- **Volume:** dezenas de milhões de linhas por mês. Uma carga ingênua em banco transacional leva horas e compete com outros usos.
- **Fragilidade:** download lento e instável, mudanças de layout e de endereço, encoding ISO-8859-1.
- **Qualidade invisível:** sem regras explícitas, um CNPJ inválido, uma data impossível ou um sócio sem empresa entram calados nas análises de crédito e de compliance.
- **Operação manual:** descobrir que saiu competência nova, baixar, carregar, validar e comparar com o mês anterior depende de alguém lembrar de fazer.

1.3 Solução proposta

Uma plataforma **on-premises, 100% em Docker**, em duas partes, seguindo a separação da arquitetura de referência:

- **Componente A — backbone analítico (determinístico).**
- **Airflow** detecta e baixa a última competência publicada.
- **DuckDB** processa todo o volume.
- **dbt** organiza o medalhão bronze → silver (com quarentena de rejeitados) → gold.
- **PostgreSQL** guarda o controle operacional e publica as tabelas de consumo.
- Um servidor **MCP** responde a perguntas em linguagem natural sobre o gold.
- **Componente B — Sentinel (probabilístico).** Um time **CrewAI** de cinco agentes lê os logs e as tabelas de quarentena, diagnostica incidentes, propõe correções que só são aplicadas com aprovação humana e escreve o post-mortem. O LLM é a API da OpenAI (configurável; Ollama local como alternativa). O Sentinel envia só metadados, contagens e trechos de log, nunca a base em massa.

1.4 Resumo do caso

Dimensão	Hoje (processo manual/scripts)	Com a plataforma
Descoberta de nova competência	Manual	Automática (verificação diária)
Download	Script, reinício manual em falha	Retomada por `Range`, integridade de zip validada
Qualidade	Implícita	100% das linhas classificadas; rejeitadas em quarentena com motivo
Histórico mês a mês	Inexistente	Métricas por competência no ledger `ops`
CNPJ alfanumérico	Não tratado	Validação de formato e DV (módulo 11 com letras)
Diagnóstico de falhas	Humano, reativo	Sentinel diagnostica e pontua contra verdade de referência
Custo	—	Licenças R$ 0 (stack open-source); só a API da OpenAI do Sentinel é paga por uso

1.5 Recomendação

Executar em fases. As Fases 0–2 (fundação, ingestão e medalhão) entregam valor sozinhas: a base completa e confiável para crédito, KYC e prospecção. O Sentinel e o MCP (Fases 3–4) só entram quando a fundação estiver provada pelos critérios de aceite da seção 8, a mesma disciplina do projeto de referência ("avaliar depois que a fundação estiver provada").

---

2. Situação atual

2.1 A fonte

Item	Valor	Evidência
Publicador	Receita Federal / SERPRO+	Compartilhamento `arquivos.receitafederal.gov.br/index.php/s/`<RFB_SHARE_TOKEN>
Acesso técnico	WebDAV público (`/public.php/webdav`), usuário = token	Mesmo compartilhamento
Periodicidade	Mensal (uma pasta `AAAA-MM` por competência)	40 pastas, de 2023-05 em diante
Tamanho por competência	~5,6 a 6 GB zipados	Listagem do compartilhamento
Arquivos por competência	37 (Empresas0–9, Estabelecimentos0–9, Socios0–9, Simples e 6 domínios)	Layout oficial

Item	Valor	Evidência
Formato	CSV sem cabeçalho, `;`, aspas `"`, ISO-8859-1	cnpj-metadados.pdf
Mascaramento	CPF de sócio com 3 primeiros e 2 últimos dígitos ocultos	Layout oficial

2.2 Volumes de referência

Medições publicadas por um pipeline open-source sobre a entrega de 2026-04 (caiopizzol/cnpj-data-pipeline, `docs/data-audit.md`):

- **Empresas:** cerca de 67 milhões (≈50 mi microempresas, ≈15 mi "demais", ≈2 mi EPP).
- **Sócios:** cerca de 27,5 milhões. Em 97% das linhas não há representante legal.
- **Estabelecimentos:** dezenas de milhões. O número exato é medido na primeira carga (métrica `linhas` em `ops.dq_metrics`).

2.3 Problemas de qualidade conhecidos na fonte

Medições da mesma auditoria (entrega 2026-04). Todos são tratados como **fatos da fonte a preservar e sinalizar**, não como erros de carga:

Caso	Ocorrência	Tratamento na plataforma
Motivo de situação `32` ausente do `Motivos.csv`	18.672 estabelecimentos	Flag `_orphan_motivo` + métrica monitorada
País órfão (14 códigos)	1.220 estabelecimentos	Flag `_orphan_pais`
UF `EX` (exterior, não documentada)	170.865 estabelecimentos	Aceita como domínio válido
Capital social `999999999999` (sentinela)	124 empresas	Flag `_capital_sentinela`
CEP com 7 dígitos (zero perdido)	~0,1% das linhas	Padronização para 8 dígitos no bronze
Representante legal `***000000**`	97% dos sócios	Convertido para nulo ("sem representante")

2.4 Processo atual (linha de base)

- O download é feito por script Python próprio (`baixa_cnpj_rf.py`), com retomada e downloads paralelos, apontando para o endereço antigo.
- A carga no PostgreSQL via `COPY` estava planejada, sem medalhão nem regras de qualidade.
- Não há controle de quais competências foram processadas, nem comparação mês a mês.
- Os tempos atuais de ponta a ponta não foram medidos. Por isso as metas da seção 8 usam o hardware de referência, e a primeira execução estabelece a linha de base.

---

3. Problema e impacto no negócio

3.1 Problema central

Os três usos-alvo dependem de a informação da empresa estar **completa, atual e correta**. Quando um desses três falha, a decisão também falha, e em silêncio.

3.2 Impacto 1 — Crédito e risco

- **Sintoma:** uma empresa baixada, inapta ou aberta há poucos meses aparece como apta porque a base está desatualizada ou incompleta.
- **Impacto:** concessão para CNPJ irregular e erro na régua de risco (idade da empresa, porte e capital social são variáveis clássicas de score).
- **Requisitos:**
- **BR-001:** processar a última competência publicada em até **24 h após a detecção**.
- **BR-002:** expor, por CNPJ, situação cadastral, data de início, porte, capital, natureza jurídica, Simples/MEI e quantidade de estabelecimentos e de sócios.

3.3 Impacto 2 — KYC / PLD

- **Sintoma:** o quadro societário e as relações entre empresas (sócio pessoa jurídica) ficam espalhados em 10 arquivos de sócios sem ligação direta com as empresas.
- **Impacto:** a verificação de beneficiário final e de grupo econômico vira trabalho manual, e o risco de não detectar empresas interligadas cresce.
- **Requisitos:**
- **BR-003:** entregar o **quadro societário completo** por CNPJ e a **rede societária PJ→PJ**, ligando empresas que são sócias de outras empresas.
- **BR-004:** manter **rastreabilidade** de cada linha até o arquivo e a competência de origem (trilha de auditoria).

3.4 Impacto 3 — Prospecção comercial

- **Sintoma:** listas por setor (CNAE principal e secundário), município, porte e aberturas recentes exigem joins pesados a cada consulta.
- **Impacto:** listas lentas e desatualizadas, com empresas já baixadas no meio.
- **Requisitos:**
- **BR-005:** consultas de prospecção por **CNAE, UF/município, porte, Simples/MEI e data de abertura** com **p95 ≤ 5 s** sobre as tabelas gold agregadas.
- **BR-006:** consulta em **linguagem natural** (MCP) restrita a intenções curadas e somente leitura.

3.5 Impacto 4 — Operação e confiabilidade

- **Sintoma:** mudança de endereço, arquivo faltando, zip corrompido ou mudança de layout só são percebidos quando alguém nota o número estranho no relatório.
- **Impacto:** retrabalho e decisões tomadas sobre dados quebrados.
- **Requisitos:**
- **BR-007:** detectar automaticamente e registrar como incidente arquivo ausente, zip corrompido, mudança de layout, queda de volume em relação ao mês anterior e aumento de rejeições.

- **BR-008:** diagnóstico assistido por agentes, com correções **sempre sujeitas a aprovação humana** e desempenho do agente **pontuado** contra casos de verdade conhecida.
- **BR-009:** processar os dados **100% on-premises**. Só o Sentinel faz chamadas externas (API da OpenAI), enviando **apenas metadados, contagens e trechos de log** (nunca linhas em massa), e nenhum segredo (inclusive `OPENAI_API_KEY`) fica no código.
- **BR-010:** suportar o **CNPJ alfanumérico** em todas as camadas.

---

4. Solução proposta e capacidades

4.1 Visão por componente

Código	Componente	Tecnologia	Responsabilidade
C1	Fonte	SERPRO+ (WebDAV)	37 arquivos por competência
C2	Ingestão	Airflow 3 + Python	Descobrir a última competência, baixar com retomada, validar zips e carregar o raw no DuckDB
C3	Transformação	dbt-duckdb	Bronze (tipagem) → silver (regras e quarentena `*_rejects`) → gold
C4	Warehouse	DuckDB	Motor colunar de todo o volume, com um único processo escrevendo
C5	Inteligência	FastAPI + MCP	Intenções curadas e somente leitura sobre o gold
C6	Consumo SQL/BI	PostgreSQL	Publicação opcional das tabelas gold para Power BI e SQL
C7	Qualidade	Monitores determinísticos	Volume mês a mês, taxa de rejeição, órfãos e frescor, gerando incidentes
B	Sentinel	CrewAI + OpenAI API	Diagnóstico, patch proposto (sob aprovação humana), post-mortem e pontuação

4.2 Requisitos funcionais

ID	Requisito	Atende
RF-01	Descobrir a competência mais recente no WebDAV e pular as já concluídas	BR-001
RF-02	Aceitar reprocessamento forçado de uma competência específica (parâmetro da DAG)	BR-001
RF-03	Baixar os 37 arquivos com retomada, tentativas com espera crescente e validação de tamanho e CRC	BR-001, BR-007
RF-04	Carregar o raw fiel à fonte (tudo texto), com `_arquivo`, `_competencia` e `_carregado_em`	BR-004
RF-05	Detectar mudança de layout antes da carga (contagem de campos)	BR-007
RF-06	Classificar 100% das linhas no silver; rejeitadas vão para `*_rejects` com `reject_rule`	BR-007

ID	Requisito	Atende
RF-07	Validar CNPJ numérico e alfanumérico (formato e DV)	BR-010
RF-08	Gold: ficha completa por estabelecimento, sócios, CNAE secundário, rede societária, painel de prospecção e resumo da competência	BR-002, 003, 005
RF-09	Registrar métricas por competência e abrir incidentes quando um limiar é violado	BR-007
RF-10	Sentinel: diagnóstico tipado, patch proposto (nunca aplicado sozinho) e post-mortem	BR-008
RF-11	Injetor de falhas para validar o Sentinel com verdade de referência	BR-008
RF-12	MCP com intenções: ficha do CNPJ, quadro societário, rede societária, prospecção e resumo	BR-006

4.3 Requisitos não funcionais

ID	Requisito	Meta
RNF-01	On-premises	Docker Desktop (WSL2) ou Docker Engine em Linux; dados nunca saem da máquina, só o Sentinel chama a API da OpenAI
RNF-02	Idempotência	Reprocessar a mesma competência produz as mesmas contagens
RNF-03	Um único escritor no DuckDB	Pool `duckdb_writer` com 1 vaga no Airflow
RNF-04	Segurança	Segredos só em `.env`; SQL parametrizado; MCP e Sentinel somente leitura
RNF-05	Observabilidade	Logs com linha de contrato `PIPELINE_FAILURE key=...`; métricas em `ops`
RNF-06	Portabilidade da fonte	URL e token da Receita configuráveis por variável de ambiente
RNF-07	LGPD	Dados já mascarados pela Receita; nenhum desmascaramento; uso restrito às finalidades declaradas

---

5. Análise de custo e esforço

Como é projeto de portfólio, a análise é de **custo total para operar** e **esforço para construir**, não de ROI corporativo.

5.1 Licenças

Item	Licença	Custo
Apache Airflow	Apache 2.0	R$ 0

Item	Licença	Custo
DuckDB	MIT	R$ 0
dbt-core / dbt-duckdb	Apache 2.0	R$ 0
PostgreSQL	PostgreSQL License	R$ 0
CrewAI	MIT	R$ 0
OpenAI API (Sentinel)	Pago por uso	Baixo: gerente `gpt-5.6-terra` (US$ 2 / US$ 12 por 1M tokens de entrada/saída) e especialistas `gpt-5.6-luna` (US$ 0,20 / US$ 1,20). Só roda quando há incidente
Ollama (alternativa local)	MIT / licença do modelo	R$ 0
Docker Desktop	Gratuito para uso pessoal	R$ 0 (ver risco R-08 para uso corporativo)

5.2 Infraestrutura de referência (estimativa a validar na Fase 1)

Recurso	Mínimo	Recomendado	Justificativa
CPU	4 vCPU	8 vCPU	DuckDB paraleliza por núcleo
RAM	16 GB	32 GB	DuckDB com `memory_limit` de 8–16 GB; +9 GB só se usar Ollama local
Disco SSD	150 GB livres	300 GB livres	Zips (~6 GB/mês), CSV temporário, warehouse, área de spill, PostgreSQL e modelos
Rede	Estável	—	~6 GB por competência; o download retoma de onde parou

5.3 Esforço de construção (1 pessoa, meio período)

Fase	Escopo	Estimativa
0	Fundação: Docker, Postgres, Airflow, estrutura do repositório	1 semana
1	Ingestão: WebDAV, download, raw, controle de competências	1–2 semanas
2	Medalhão dbt, regras de qualidade, monitores	2 semanas
3	Consumo: publicação no Postgres, MCP, painel	1–2 semanas
4	Sentinel: crew, injetor de falhas, pontuação	2 semanas
5	Endurecimento: testes de volume real, documentação e demo	1 semana
Total		**8–10 semanas**

5.4 Benefício esperado

- **Operação:** a competência mensal passa a ser processada sem intervenção. O trabalho manual se resume a aprovar patches propostos pelo Sentinel e ler os post-mortems.

- **Portfólio:** demonstra ponta a ponta as competências mais pedidas em vagas de engenharia de dados e IA (orquestração, modelagem medalhão, qualidade de dados, MCP e sistemas multiagente avaliados contra verdade de referência).
- **Reuso:** a base gold atende os três casos de uso com o mesmo pipeline.

---

6. Alternativas consideradas

Critério	A. Manter scripts + `COPY` no Postgres	B. Arquitetura de referência original (Dagster)	C. APIs comerciais de CNPJ	D. Proposta: Airflow + DuckDB + dbt
Processa 100% da base	Sim, lento	Sim	Não (consulta por CNPJ)	**Sim**
Desempenho no volume	Baixo (engine OLTP)	Alto (DuckDB)	N/A	**Alto (DuckDB)**
Qualidade explícita	Não	Sim	Caixa-preta	**Sim (quarentena)**
Custo recorrente	Baixo	Baixo	Por consulta	**Baixo**
Dependência de terceiros	Nenhuma	Nenhuma	Alta	**Nenhuma**
Aderência ao mercado/stack do autor	Média	Média (Dagster menos difundido)	—	**Alta (Airflow é padrão de mercado)**
Recomendação	❌ Não resolve qualidade nem operação	⚠️ Viável; troca de orquestrador por decisão do projeto	❌ Não atende rede societária nem análise em massa	✅ **Seguir**

Nota sobre a escolha do orquestrador. A vazão no volume vem do **DuckDB** (motor colunar, vetorizado e com spill em disco), não do orquestrador. O Airflow foi escolhido por maturidade, adoção de mercado e controle de concorrência por *pools*, que resolve a regra de um único escritor do DuckDB.

---

7. Riscos e mitigação

7.1 Riscos técnicos

ID	Risco	Prob.	Impacto	Mitigação
R-01	A Receita muda de novo o endereço ou o token	Média	Alto	URL e token no `.env`; incidente `missing_file`/falha de listagem; runbook
R-02	Mudança de layout (coluna nova ou removida)	Baixa	Alto	Checagem de campos antes da carga (`layout_drift`); layout centralizado em um módulo
R-03	Download instável ou lento	Alta	Médio	Retomada por `Range`, espera crescente, detecção de download travado e validação de CRC

ID	Risco	Prob.	Impacto	Mitigação
R-04	Falta de memória ou disco no processamento	Média	Alto	`memory_limit` e `temp_directory` do DuckDB; processamento arquivo a arquivo; CSV temporário apagado após carga
R-05	Dois processos escrevendo no DuckDB	Média	Médio	Pool de 1 vaga; DAG com `max_active_runs=1`; leitores em modo somente leitura
R-06	Diagnóstico fraco ou custo de API acima do esperado	Média	Médio	Monitores determinísticos continuam valendo; tiering de modelos (gerente forte, especialistas baratos); Sentinel só roda com incidente aberto; pontuação expõe a qualidade real
R-13	Envio de dados à OpenAI	Média	Médio	Ferramentas dos agentes só devolvem agregados e amostras pequenas de dado público; `SENTINEL_LLM_PROVIDER=ollama` troca para LLM local sem mudar código
R-07	CNPJ alfanumérico quebra validações	Média	Alto	Regex `[0-9A-Z]` e DV com `ascii(c) - 48` nas regras do silver
R-08	Licença do Docker Desktop se o projeto virar uso corporativo	Baixa	Médio	Docker Engine em Linux, Rancher Desktop ou Podman (o compose é o mesmo)
R-09	Desempenho ruim de volumes montados no Windows	Alta	Médio	Usar volumes nomeados do Docker ou manter o repositório no filesystem do WSL2
R-10	Proxy corporativo com inspeção TLS	Baixa	Médio	`HTTPS_PROXY` e `RFB_CA_BUNDLE` suportados

7.2 Riscos de uso (LGPD e ética)

ID	Risco	Mitigação
R-11	Uso de dados de sócios pessoa física fora da finalidade	A base já vem mascarada pela Receita; nenhuma tentativa de desmascarar; finalidades declaradas (crédito, KYC, prospecção B2B)
R-12	Prospecção indevida de pessoa física	Prospecção restrita a dados da pessoa jurídica (CNAE, local, porte)

---

8. Métricas de sucesso e governança

8.1 Critérios de aceite (verificados por medição, nunca declarados)

AC	Prova	Meta	Como medir
AC-1 Completude	37/37 arquivos carregados; linhas do raw iguais às linhas do CSV	Erros de parsing ≤ 0,001%	`raw.raw_load_log`
AC-2 Tempo de processamento	Carga + dbt + monitores de uma competência	≤ 4 h no hardware recomendado	Duração da DAG no Airflow
AC-3 Frescor	Da detecção da nova competência até o gold	≤ 24 h	`ops.competencias`

AC	Prova	Meta	Como medir
AC-4 Qualidade	100% das linhas classificadas; nenhuma rejeitada chega ao gold	0 vazamentos	Testes dbt + eval de sobrevivência de defeitos
AC-5 Consulta	Intenções MCP e tabelas gold agregadas	p95 ≤ 5 s	Eval de latência
AC-6 Sentinel	Casos injetados diagnosticados corretamente	Match médio ≥ 0,8	`ops.diagnoses` (pontuação contra `origin='chaos'`)
AC-7 Idempotência	Reprocessar a competência	Contagens idênticas	Comparação de `ops.dq_metrics`
AC-8 Soberania dos dados	O pipeline não faz chamadas externas além da Receita; o Sentinel envia só agregados	0 linhas de dado em massa nos prompts	Revisão das ferramentas + log de prompts

AC-1 é o go/no-go. Sem completude comprovada, nenhuma camada acima é confiável.

8.2 KPIs de operação

KPI	Meta (mês 3)	Fonte
Competências processadas sem intervenção	≥ 90%	`ops.competencias`
Tempo médio até diagnóstico de incidente (MTTD)	≤ 15 min após o fim da DAG	`ops.incidents` vs `ops.diagnoses`
Taxa de rejeição por entidade	Estável (±0,1 p.p. mês a mês)	`ops.dq_metrics`

8.3 Governança

- **Dono do produto e do código:** Bruno Nunes.
- **Revisão:** a cada fase, com demonstração e verificação dos AC da fase.
- **Mudanças de arquitetura:** registradas como ADR em `docs/adrs/`.

---

9. Roadmap de implementação

Fase 0 — Fundação (semana 1)

- **Entregas:** `docker-compose` (PostgreSQL, Airflow, Sentinel/MCP; Ollama opcional), `.env`, estrutura do repositório.
- **Critério de saída:** `docker compose up` saudável; Airflow acessível; schema `ops` criado.

Fase 1 — Ingestão (semanas 2–3)

- **Entregas:** cliente WebDAV, download com retomada, controle de competências, carga raw e log de carga.
- **Critério de saída: AC-1** com uma competência real.

Fase 2 — Medalhão e qualidade (semanas 4–5)

- **Entregas:** modelos dbt bronze/silver/gold, regras de quarentena, seeds de domínio e monitores.
- **Critério de saída: AC-2, AC-4 e AC-7**.

Fase 3 — Consumo (semanas 6–7)

- **Entregas:** publicação no PostgreSQL, servidor MCP com intenções curadas, consultas de exemplo para Power BI.
- **Critério de saída: AC-5**.

Fase 4 — Sentinel (semanas 8–9)

- **Entregas:** crew hierárquico de 5 agentes, ferramentas somente leitura, injetor de falhas, gatilho e pontuação.
- **Critério de saída: AC-6 e AC-8**.

Fase 5 — Endurecimento e demo (semana 10)

- **Entregas:** execução com duas competências reais seguidas, guia de operação e vídeo/demo.
- **Critério de saída: AC-3** e KPIs da seção 8.2 medidos.

---

10. Partes interessadas e personas

Persona	Necessidade	O que a plataforma entrega
Analista de crédito	Situação, idade, porte, capital e Simples de um CNPJ	Ficha do CNPJ (gold + intenção MCP `ficha_cnpj`)
Analista de KYC/PLD	Quadro societário e empresas interligadas	`gold_socios_detalhe`, `gold_rede_societaria`, intenção `rede_societaria`
Time comercial	Listas de empresas ativas por setor e região	`gold_painel_prospeccao`, intenção `prospectar`
Engenheiro de dados (operação)	Saber o que quebrou e por quê	Incidentes, diagnósticos e post-mortems do Sentinel
Avaliador técnico / recrutador	Ver a arquitetura funcionando e medida	Repositório, ADRs, AC medidos e demo

---

11. Registro de premissas e restrições

11.1 Premissas

ID	Premissa	Confiança	Se estiver errada	Mitigação
A-01	A Receita mantém publicação mensal no SERPRO+ via WebDAV	Média	Ingestão para	URL configurável; incidente de falha de listagem

ID	Premissa	Confiança	Se estiver errada	Mitigação
A-02	Uma competência cabe no hardware recomendado com spill em disco	Alta	AC-2 falha	Aumentar RAM/disco; processar por entidade
A-03	O layout de 2026 segue o `cnpj-metadados.pdf`	Alta	Carga falha em `layout_drift`	Layout centralizado em um módulo, correção em um lugar
A-04	Os modelos `gpt-5.6-luna` (especialistas) e `gpt-5.6-terra` (gerente) diagnosticam os casos injetados	Média	AC-6 abaixo da meta	Subir o tier do modelo por configuração
A-05	Os dados são usados só para as finalidades declaradas	Alta	Risco LGPD	Seção 7.2

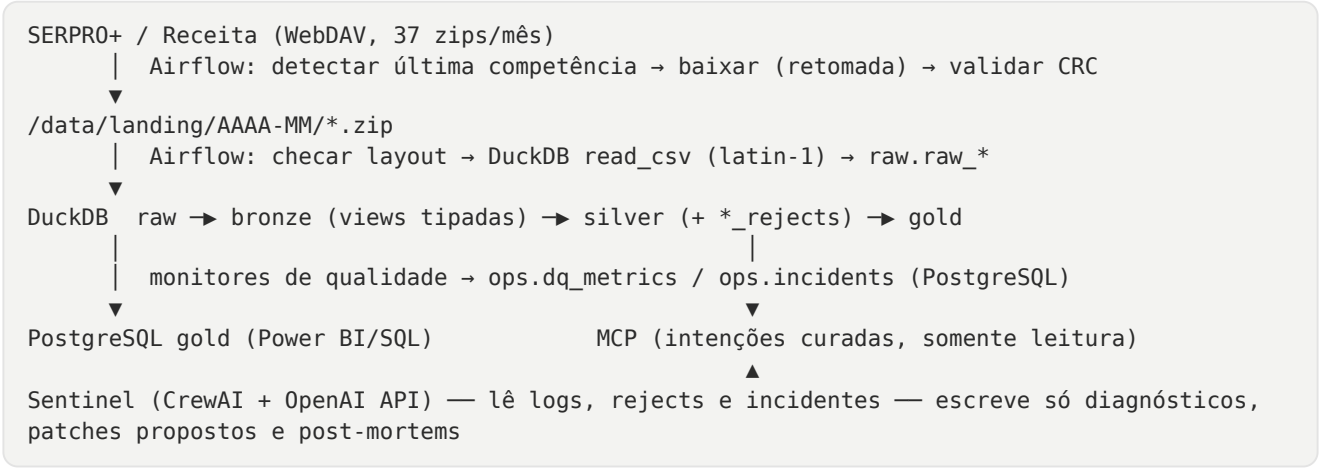
11.2 Restrições

ID	Restrição	Impacto	Mitigação
C-01	Uma pessoa, meio período	Cronograma de 8–10 semanas	Entregas por fase com valor isolado
C-02	Dados on-premises	Sem warehouse gerenciado; só o LLM é externo	Stack 100% em containers; LLM trocável por Ollama
C-03	DuckDB aceita um único escritor	Tarefas de escrita em série	Pool de 1 vaga
C-04	Estação Windows com Docker Desktop	I/O de bind mount lento	Volumes nomeados / WSL2

---

12. Apêndice: arquitetura-alvo

12.1 Fluxo de dados



12.2 Separação dos componentes (regra R3 da referência)

- O **Componente A** produz. O **Sentinel** observa, sempre somente leitura.
- O único caminho do Sentinel de volta ao pipeline é o **patch proposto**, que um humano revisa e aplica.

- O Sentinel é **pontuado** contra o ledger de incidentes injetados, nunca declarado correto.

12.3 Stack (referência)

Airflow 3.3 · DuckDB 1.5 · dbt-core 1.12 + dbt-duckdb 1.11 · PostgreSQL 17 · FastAPI + MCP · CrewAI 1.x · OpenAI API (Ollama opcional) · Docker Compose · Python 3.12.

---

13. Conclusão

A plataforma transforma uma publicação mensal grande e instável numa base confiável e rastreável para **crédito e risco, KYC/PLD e prospecção**. Os dados são processados inteiramente em infraestrutura própria, sem custo de licença (só a API do Sentinel é paga por uso), e a qualidade é **medida** (critérios AC-1 a AC-8). Com o Sentinel, o projeto também demonstra um sistema multiagente avaliado contra verdade de referência, que é a parte mais difícil e menos comum em portfólios.

Recomendação: iniciar pelas Fases 0–2 e usar AC-1 como portão de decisão.

Versão: 1.0 · **Última atualização:** 11/09/2026 · **Próxima revisão:** ao fim da Fase 1