ENGINEERING BRIEF · DEFINIÇÃO DO PROBLEMA · PASSO 1 DE 4 (CONVERGE)

Uma base pública, decisões no escuro.

Todo mês a Receita Federal publica o cadastro completo das empresas brasileiras. Quem decide crédito, conformidade e prospecção depende dele — mas hoje o consome sem saber se está completo, atual ou correto. Este brief define esse problema: quem sofre, o que "resolvido" precisa provar e o que *não* estamos resolvendo agora. Ele deliberadamente não nomeia tecnologia; a solução vem no Passo 2.

PREPARADO POR	PROPÓSITO	ESCOPO	DATA
Bruno Nunes · Engenharia de Dados	Consenso sobre o problema	Problema, não solução	11 de setembro de 2026

TRÊS SINAIS VITAIS — COMO ESTÃO HOJE → COMO PRECISAM FICAR

Tempo da publicação da Receita até a base estar utilizável

`indefinido → ≤ 24 h`

Linhas verificadas por regra de qualidade explícita

`0% → 100%`

Competências processadas sem intervenção manual

`0 → ≥ 90%`

01 O problema, em termos simples

causa raiz

A fonte é **grande, instável e imperfeita**: 37 arquivos por mês (cerca de 6 GB compactados, dezenas de milhões de linhas), publicados num servidor lento que já mudou de endereço, com layout sujeito a mudança, um formato de CNPJ novo desde julho de 2026 e defeitos que a própria Receita publica (códigos sem descrição, CEPs sem o zero à esquerda). Do outro lado, o consumo é **manual e sem verificação**: alguém precisa lembrar de baixar, carregar e conferir.

Esse descompasso é a causa raiz. Tudo o que vem abaixo — base velha, base quebrada, defeito que ninguém vê, trabalho repetido — é sintoma dele. A correção não é um script mais rápido: é tornar o ciclo mensal **automático, completo e verificável**, de forma que cada decisão saiba em que dado está apoiada.



FIG. 1 — UM DESCOMPASSO NA ORIGEM SE DESDOBRA EM QUATRO DORES E CHEGA ÀS DECISÕES.

02 Quem sofre, e como

mapa de impacto

Analista de crédito RISCO

Precisa de situação cadastral, idade, porte, capital e Simples/MEI de um CNPJ. Se a base está atrasada, aprova para empresa baixada ou inapta; se está incompleta, recusa quem não devia.

`decisão por CNPJ · segundos por consulta`

Analista de KYC/PLD CONFORMIDADE

Precisa do quadro societário e das empresas interligadas (sócio pessoa jurídica). Sem histórico, não enxerga quem entrou ou saiu da sociedade; sem ligação entre arquivos, monta a rede à mão.

`quadro atual + mudanças em 12 meses`

Time comercial RECEITA

Precisa de listas de empresas ativas por setor, região, porte e abertura recente. Listas com empresas baixadas desperdiçam esforço de venda.

`listas por CNAE · UF · município · porte`

Engenharia de dados OPERAÇÃO

Carrega o ciclo mensal nas costas: descobrir a publicação, baixar 6 GB de um servidor instável, carregar, conferir e explicar números estranhos depois.

`trabalho manual todo mês · falhas descobertas tarde`

03 Onde estamos vs. onde precisamos estar

resultado, não desenho

Descreve uma **propriedade desejada** — o ciclo mensal acontece sozinho e cada linha tem veredito — não como construir isso.

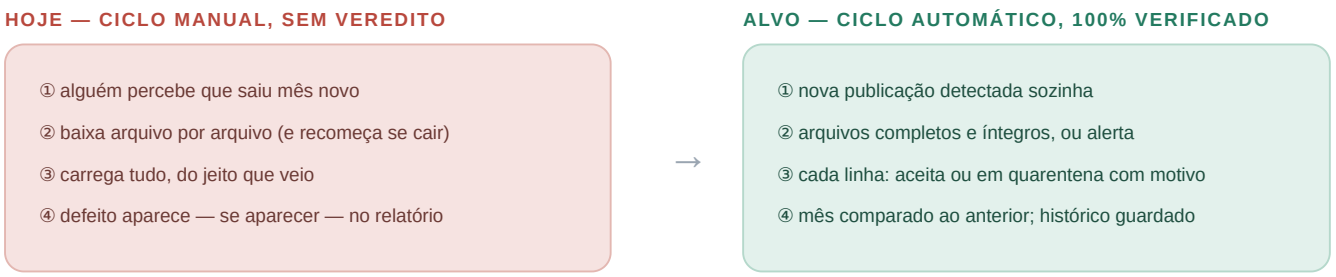


FIG. 2 — A MUDANÇA É CONCEITUAL: DE "CARREGADO" PARA "VERIFICADO". O "COMO" FICA PARA O PASSO 2.

04 O que este problema é — e não é

fronteira de escopo

✓ No escopo — o que resolvemos agora (v1)

- Processar 100% dos arquivos da **última competência publicada**, sem intervenção
- Dar veredito a 100% das linhas: aceita, ou em quarentena com o motivo
- Suportar o CNPJ alfanumérico em todo o ciclo
- Avisar quando a fonte falha: arquivo ausente, corrompido, layout novo, queda de volume
- Comparar cada mês com o anterior e guardar **12 meses de histórico**
- Entregar ficha por CNPJ, quadro societário, rede entre empresas e listas de prospecção

× Fora do escopo — problemas separados

- Consulta em linguagem natural
  experiência de consumo — fase 2, depois da fundação provada
- Diagnóstico autônomo de incidentes por agentes
  automação de operação com risco próprio — fase 2
- Histórico linha a linha com vigência (por CNPJ/sócio)
  v1 guarda fotos mensais; vigência é evolução futura
- Enriquecimento com outras fontes (endereço, faturamento)
- Programa de privacidade/LGPD
  contatos seguem como a Receita publica; risco aceito (seção 07)
- Qualquer escolha de tecnologia — isso é o Passo 2

05 O que "pronto" precisa provar

aceite verificável

Cada critério é um teste de passa/não passa ligado a um KPI do BRD. "Pronto" não é "parece funcionar": é esta medição, feita desta forma.

ID	Critério de aceite (verificável)	Como verificamos	KPI que prova
AC-1	**Completude.** Os 37 arquivos da competência são processados; linhas lidas = linhas publicadas, com erro de leitura ≤ 0,001%.	Registro de carga por arquivo, comparado ao arquivo publicado.	Competências completas não medido → 100%
AC-2	**Tempo de processamento.** Com os arquivos já locais, a competência fica utilizável em ≤ 4 h no hardware de referência.	Duração registrada do ciclo, da carga ao consumo.	Tempo de processamento indefinido → ≤ 4 h
AC-3	**Frescor.** Da detecção de nova publicação até o dado utilizável: ≤ 24 h.	Hora de detecção vs. hora de conclusão, por competência.	Frescor indefinido → ≤ 24 h
AC-4	**Veredito total.** 100% das linhas classificadas; nenhuma linha em quarentena chega às tabelas de consumo.	Contagem aceitas + quarentena = lidas; verificação de vazamento.	Linhas verificadas 0% → 100%
AC-5	**Consulta.** Consultas agregadas de prospecção e resumo respondem em p95 ≤ 5 s.	Bateria de consultas padrão, cronometrada.	Latência p95 não medido → ≤ 5 s

AC-6	**Reprocessável.** Reprocessar a mesma competência produz exatamente as mesmas contagens.	Duas execuções, métricas comparadas.	Confiabilidade — → idêntico
AC-7	**Alerta da fonte.** Arquivo ausente, corrompido, mudança de layout e queda de volume viram alerta registrado em 100% dos casos simulados.	Falhas simuladas contra uma cópia da competência.	Falhas descobertas tarde comum → 0
AC-8	**Histórico.** As últimas 12 competências ficam consultáveis e comparáveis.	Consulta a uma competência antiga e diferença entre duas.	Meses consultáveis 1 → 12

AC-1 é o go/no-go. Sem completude provada com uma competência real, nada acima dela é confiável.

06 Métricas de sucesso

atual → alvo

Métrica	Atual	Alvo (mês 3)	Fonte (BRD)
Competências processadas sem intervenção	0	≥ 90%	KPI 8.2
Tempo da detecção à base utilizável	indefinido	≤ 24 h	BR-001
Linhas com veredito de qualidade	0%	100%	BR-007
Oscilação da taxa de quarentena mês a mês	não medida	± 0,1 p.p.	KPI 8.2

07 Interrogatório do Passo 1 e premissas abertas

decidido em 11/09/2026

1 · Histórico. KYC e crédito precisam ver mudanças. *Default proposto:* guardar foto mensal compacta, 12 meses. **Decisão:** aceito — 12 meses de histórico (AC-8). Dono: Bruno (produto).

2 · Contato de pessoa física na prospecção. MEI e empresário individual são pessoas físicas. *Default proposto:* omitir contato deles nas listas. **Decisão:** manter os contatos como a Receita publica. Registrado como **risco aceito** (LGPD) — dono: Bruno; revisar se o uso deixar de ser pessoal.

3 · Escopo da consulta em linguagem natural e dos agentes. *Default proposto:* no v1, atrás do portão AC-1. **Decisão:** fora do v1 — fase 2, depois da fundação provada.

ID	Premissa	Se estiver errada
P-01	A Receita segue publicando uma pasta por mês no repositório atual.	O ciclo para; o alerta da fonte (AC-7) precisa avisar.
P-02	Uma competência cabe no hardware de referência (16–32 GB, SSD).	AC-2 falha; revisar hardware.
P-03	O layout segue o documento oficial de metadados.	AC-7 dispara; ajuste em um único lugar.
P-04	Uso pessoal/portfólio, sem compartilhamento de listas com terceiros.	Reabrir a decisão 2 (LGPD).